Operating Systems

Isfahan University of Technology Electrical and Computer Engineering Department

Zeinab Zali

Synchronization

هماهنگ سازی



Background

- Processes can execute concurrently
 - May be interrupted at any time, partially completing execution
- Concurrent access to shared data may result in data inconsistency
- Maintaining data consistency requires mechanisms to ensure the orderly execution of cooperating processes



توی سیستم پروسس ها ممکنه که همزمان اجرا بشن و هر پروسسی ممکنه که در هر لحظه ای بخاطر وقفه ای که اتفاق افتاده متوقف بشه بنابر این اجراش یه جورایی ناتموم می مونه حالا اگر پروسس های همزمانی داشته باشیم که یک دیتای مشترک رو دارند استفاده می کنند ممکنه

دسترسی نادرست به اون دیتای مشترک باعث data inconsistency ینی اون مقداری که ما انتظار داریم توی اون شیر دیتا باشه توی اون شیر دیتا نخواهد بود بنابراین اون چیزی که میخوایم حل بکنیم و روش کار بکنیم قسمت ابی رنگ است:

بنی می خوایم مکانیز به هایی داشته باشیم که مطمئن بشیم بر و سس هایی که با هم دیگه یک تعاملی

کل بحدیم و روس کار بحدیم فسمت آبی رکت آست. ینی می خوایم مکانیزیم هایی داشته باشیم که مطمئن بشیم پروسس هایی که با هم دیگه یک تعاملی دارند یا یک شیر دیتایی دارند ترتیب اجرایی خواهند داشت که باعث data inconsistency

نمیشه یا یک ترتیب درست است که باعث میشه دیتامون همانطور که می خوایم consistency باشه و باشه و consistency همان طور که گفتیم منظور مون این است که اون چیزی که انتظار داشتیم

اتفاق بیوفته ینی ما برنامه نویس که اون کد رو نوشتم چه انتظاری داشتم از اون کدی که نوشتم: دیتاها مقادیر شون بعد از اجرای اون کد به همون صورتی باشه که ما انتظار داشتیم نه اینکه با یک ترتیب اشتباهی اجرا شده باشه که باعث شده باشه مقادیر دیتا اونطوری که میخوایم نباشه

Illustration of the problem: Calculating summation of numbers with some threads

- We want to calculate the summation of some numbers with more than one thread to speed up the operation
- Consider a global variable sum
- We use data parallelism, divide numbers in to some sets, create a thread for each set to add numbers to sum
- Execute the code in next page and see the result

-چندتا مثال برای روشن شدن مسئله: 1- قبلا اینو گفتیم

2- بحث جمع کردن یک تعداد عدد است ینی یک تعداد زیادی عدد داریم و می خوایم جمع این ها رو توی یک متغییری محاسبه بکنیم چون تعداد اعداد زیاده میایم توی چندتا ترد این جمع رو انجام میدیم ینی تا n رو می خوایم جمع بکنیم و اینو مثلا تقسیم می کنیم به 4 تا ترد و هر قسمت رو از اون اعداد رو جدا جدا جمع می زنیم توی ترد و روشمون هم به این صورت است که یک global

variable به نام sum که قبل از اجرای این تردها مقدارش صفره و بعد اون عددهایی که داخل اون تردها است به این مقدار Sum توی هر تردی به طور جداگانه اضافه میشه و انتظار داریم وقتی که این 4 تا ترد تموم شد مقدار sum برابر با جمع کلش بشه: کدش صفحه بعدی...

et, Put ty tan

Illustration of the problem: Calculating summation of numbers with some threads

```
Concurrency problem
*************************************
#include <pthread.h>
#include <stdio.h>
#include <stdlib.h>
struct thread input{
int b;
int e:
};
int sum = 0:
void *summation thread(void *input)
 struct thread input *arg;
 arg = (struct thread input*)input;
 for (int i=arg->b; i<=arg->e; i++){
 sum += i;
 pthread_exit(NULL);
```

```
int main(int argc, char *argv[])
  int n = 10000000;
 pthread_t threads[NUM_THREADS];
  int rc, t;
 struct thread input beg_end[NUM_THREADS];
 int d = n / NUM THREADS;
 for(t=0;t<NUM THREADS;t++){
     beg end[t].b = t * d + 1;
      beg end[t].e = beg end[t].b + d - 1;
      rc = pthread_create(&threads[t], NULL, summation_thread, (void
      *)&beg end[t]);
      if (rc){
             printf("ERROR; return code from pthread create() is %d\
      n", rc);
             exit(-1);
 for (t=0;t<NUM_THREADS;t++){
       pthread join(threads[t], NULL);
  printf("sum= %d\n", sum);
 /* Last thing that main() should do */
  pthread_exit(NULL);
```

Illustration of the problem: updating a linked list

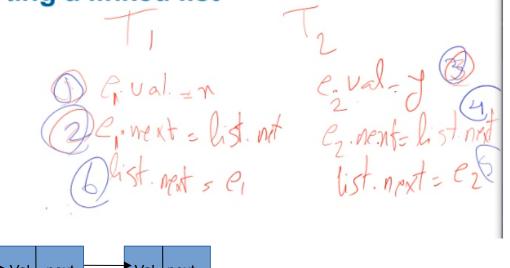
Create new list element e

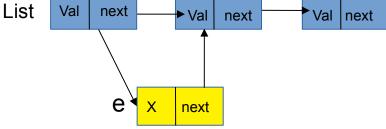
Set e.value = X

Read list and list.next

Set e.next=list.next

Set list.next=e





What happens if two threads try to add an element concurrently to the same list??

مثال بعدى:

در مورد لینکدلیست است

فرض میکنیم یک لینکدلیستی داریم و می خوایم اینو اپدیتش بکنیم ینی میخوایم یک المنت جدیدی به این لینکدلیست اضافه بکنیم

ما اگر یک فانکشنی نوشته باشیم برای اینکه این المان جدید رو به این لینکدلیست اضافه بکنیم و این فانکشن رو ممکنه ما جاهای مختلفی توی پروگرمی که نوشتیم استفاده بکنیم توی تردهای مختلفی و باعث بشه یه جایی توی دوتا ترد همزمان این فانکشن فراخوانی بشه در این حالت اتفاقی که می افته

باعث بسه یه جایی توی دون نرد همرهان این قانانس فراخوانی بسه در این است که : این است که : مثلا ترد T1 داره x رو اضافه میکنه و ترد T2 هم داره y اضافه میکنه

اگر فرض کنیم که T1, T2 دارن همزمان اجرا میشن شماره هایی که کنار دستورات هست ینی به این ترتیب دارن اجرا میشن توی این لیست اول ۷ اضافه شد

توی شماره 6 افتاقی که می افته اینه که اول list.next به e1 وصل میشه و بعد از اون list.next که به e2 وصل بوده حذف میشه و در نهایت اون لیستی که می بینیم لیستیه که x بهش اضافه شده و y توش وجود نداره ینی توی این لیست حساب نمیشه انتظار ما این بود که وقتی که این دوتا ترد اجرا شد قسمت سبزرنگ ساخته میشد

List Val next Val next Wal nex

Illustration of the problem: producer-consumer problem

- Suppose that we wanted to provide a solution to the consumer-producer problem that fills all the buffers.
- We can do so by having an integer counter that keeps track of the number of full buffers.
- Initially, counter is set to 0.
- counter is incremented by the producer after it produces a new buffer and is decremented by the consumer after it consumes a buffer.

كدش صفحه بعدى

مسئله بعدی مسئله producer-consumer است:

فرض کنید بخاطر اینکه بافرمون محدود است میخوایم از یک کانتری استفاده بکینم که هم چک بکنه

اگر بافر پر بود تولید کننده دیگه نمیتونه مقدار جدیدی توش قرار بده و هم اینکه اگر بافر خالی بود

مصرف کننده باید صبر بکنه که تولیدکننده یک مقداری توی بافر قرار بده

Producer

```
while (true) {
    /* produce an item in next produced */
    while (counter == BUFFER_SIZE) ;
        /* do nothing */
    buffer[in] = next_produced;
    in = (in + 1) % BUFFER_SIZE;
    counter++;
}
```

Consumer

```
while (true) {
    while (counter == 0)
        ; /* do nothing */
    next_consumed = buffer[out];
    out = (out + 1) % BUFFER_SIZE;
        counter--;
    /* consume the item in next consumed */
}
```

Race Condition

counter++ could be implemented as

```
register1 = counter
register1 = register1 + 1
counter = register1
```

counter-- could be implemented as

```
register2 = counter
register2 = register2 - 1
counter = register2
```

Consider this execution interleaving with "count = 5" initially:

```
S0: producer execute register1 = counter {register1 = 5}
S1: producer execute register1 = register1 + 1 {register1 = 6}
S2: consumer execute register2 = counter {register2 = 5}
S3: consumer execute register2 = register2 - 1 {register2 = 4}
S4: producer execute counter = register1 {counter = 6}
S5: consumer execute counter = register2 {counter = 4}
```



حالتی که این دوتا پنی تولید کننده و مصرف کننده دارن توی دوتا ترد جداگانه اجرا میشن و همزمان این دوتا ترد به خط ایدیت کردن کانتر می رسن ینی به خط counter--, counter++ اتفاقى كه مى افته: از توی اسلاید بخون

اگر قبلش counter=5 بوده بعد از اجرای این دوتا هم باز باید counter=5 میشد ولی این مقدار ابنجا با 4 میشه با 6

نکته: اینجا دوتا پروسسور داریم پس اینطوری نشون داده میشه که وقتی که تک پروسسور داریم مشکلی پیش نمیاد در صورتی که حتی اگر تک پروسسور هم داشته باشیم هم باز ممکنه مشکل پیش بیاد چرا؟ چون مسئله به این بر میگر ده که ما اون خط کدی که توی برنامه نوشتیم ینی counter++ یا counter- است وقتی که می خواد باینریش تولید میشه و کامپایل میشه اسمبلی میشه و بعد اسمبلی میاد باینری میشه و توی اسمبلی یک عملیات جمع به یک همچین چیزی تبدیل میشه که توی

اسلاید روبرو نوشته پنی + پنی اون مقداری که توی حافظه است باید بره توی رجیستر cpu و بعد رجیستر cpu هست که میتونه زیاد بشه و بعد رجیستر cpu ذخیره بشه توی اون قسمت حافظه

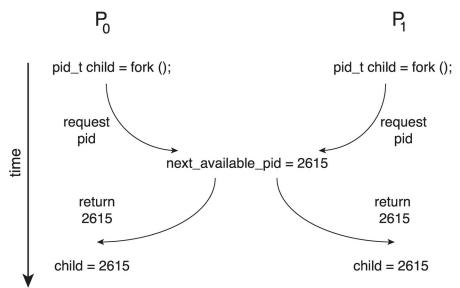
حالاً فرض میکنیم یک cpu داریم و زمان بندی این دونا پروسس توی این cpu به این صورت است پنی *: پنی به نوعی این ها زمان بندی میشن که به این ترتیب این خط ها بینابین هم اجرا

میشن پس با وجود یک cpu هم اجرای همزمان این دوتا ینی تایم شیرینگشون باعث ایجاد مشکل شد



Race Condition

- Processes P₀ and P₁ are creating child processes using the fork()
 system call
- Race condition on kernel variable next_available_pid which represents the next available process identifier (pid)



• Unless there is a mechanism to prevent P₀ and P₁ from accessing the variable next_available_pid the same pid could be assigned to two different processes!

یک نمونه دیگه ای که توی کرنل اتفاق می افته تا مسئله Race Condition رو بتونیم ببینیم: Race Condition موقعی است که برای تغییر یک ریسورس یا اپدیت یک ریسورس مشترک بین

دوتا پروسس یا دوتا تردی که همزمان دارن اونو ایدیت می کنن یک رقابتی پیش بیاد و اگر ما رقابتشون رو در نظر نگیریم و نخوایم ترتیب اجرا بهشون بدیم باعث میشه که data consistency پیش بیاد و اون چیزی که مد نظرمون هست دیتا ایدیت نشه

اینجا مثال کرنل رو می بینیم: جایی که کرنل میخواد فورک بکنه:

اگر توی اون سرویس روتین فورک همزمانی بیش بیاد بنی توی دوتا پروسس همزمان فورک

فراخوانی بشه و باعث بشه توی پروسس اول که فورک ایجاد شده و تا اون خطش که یک pid جدید

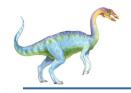
بخواد بهش داده بشه انجام بشه مثلا pid قبلی که داشتیم مثلا 2614 بوده و p0 که فورک میشه

کرنل بهش 2615 رو میده

اینجا برای p0 , p1 اگر همزمان pid جدید بخواد ریکوست بشه همزمان اون available pid جدید یک مقدار مشترک خواهد داشت برای این دوتا پروسس و برای هر دوی این ها اون مقداری

که برگر دونده میشه برای اون پروسس جدید یک مقدار واحد است و اینجا به مشکل می خوریم چرا؟ چون کد فورک که داشت اجرا میشد همزمانی توی اجرای این کد فورک اتفاق افتاد

پس همونطوری که توی برنامه های سطح یوزر ممکنه همزمانی پیش بیاد و مشکل ایجاد بشه توی برنامه های سطح کرنل هم اجرای همزمان دوتا دستور کرنل می تونه باعث ایجاد مشکل بشه



Critical Section Problem

- Consider system of n processes $\{p_0, p_1, \dots p_{n-1}\}$
- Each process has critical section segment of code
 - Process may be changing common variables, updating table, writing file, etc.
 - When one process in critical section, no other may be in its critical section
- Critical section problem is to design protocol to solve this
- Each process must ask permission to enter critical section in entry section, may follow critical section with exit section, then remainder section



Critical Section مسئله فرض کنید n تا پروسس توی سیستم داریم از p0 تا pn-1 و هر کدوم این ها هم یک قسمت

Critical دارن و منظور م از Critical جیه؟ اون جایی هست که یک Critical داره اپدیت میشه بین این پروسس ها حالا میتونه یک متغییر باشه یا یک جدول مشترک باشه یا یک فایل باشه و... به هرحال چندتا از این پروسس ها بخوان همزمان یک فایل مشخص یا یک جدول

مشخص یا یک متغییر مشخص رو تغییر بدن اون قسمتی از کد که این تغییر ات توش اعمال میشه بهش میگیم critical section

همیشه مسئله همزمانی برای ما پیش نمیاد بستگی به نحوی اجرای این پروسس ها داره اگر p0, p1, p2 داشته باشیم و هر سه تاشون هم یک critical section داشته باشند که دارن

یک متغییر و آحدی رو توش تغییر میدن در این صورت اگر همشون همزمان وارد این critical

section نشن ما مشکلی نداریم بنابراین مسئله critical section تعریف شده که ما با حلش مطمئن بشیم که این همزمانی پیش میاد ینی در یک زمان واحد حداکثر فقط یکی از این پروسس ها توی critical section شون قرار

میگیرن پس ما می خوایم مسئله رو به نوعی اجرا بکنیم که به هر ترتیبی این n تا پروسس ها اجرا بشن توی cpu یا cpu ها مطمئن بشیم که موقعی اجرا توی یک لحظه واحد فقط یکیشون توی قسمت critical section است و بقیه دارن کدهایی رو اجرا می کنن که خارج از section شون هستن

به اون نقطه ای که وارد critical section میشیم entry section و به اون نقطه ای که داریم خارج میشیم می گیم exit section

و بقیه کد رو ینی کدهایی که داخل critical section نیست رو میگیم remainder section



Critical Section

General structure of process P;

```
while (true) {

entry section

critical section

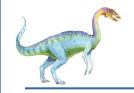
exit section

remainder section
```



مثل این:

این while(true) هم به این معنیه که ممکنه این تیکه کد تکرار بشه اجراش



Critical-Section Problem (Cont.)

Requirements for solution to critical-section problem

- 1. Mutual Exclusion If process P_i is executing in its critical section, then no other processes can be executing in their critical sections
- 2. Progress If no process is executing in its critical section and there exist some processes that wish to enter their critical section, then the selection of the process that will enter the critical section next cannot be postponed indefinitely
- 3. Bounded Waiting A bound must exist on the number of times that other processes are allowed to enter their critical sections after a process has made a request to enter its critical section and before that request is granted
 - Assume that each process executes at a nonzero speed
 - No assumption concerning relative speed of the n processes



اگر بخوایم یک راه حلی برای مسئله critical section بدیم باید چه ویژگی هایی داشته باشه؟ 1- Mutual Exclusion يا انحصار نامتقابل: فقط يكي از اين يروسس ها بين n تا يروسس مي تونه توی critical section اش باشه و بقیه مطمئنیم که خارج از critical section شون هستن 2- Progress: اگر هیچ پروسسی الان توی critical section اش نیست و یک پروسسی مایله که وار د critical section اش بشه روشی که ما ارائه می کنیم باید اجازه بده که اون پروسس وارد critical sectionاش بشه و ما یه جوری روش رو ارائه نداده باشیم که با این که بقیه پروسس ها نمی خوان وارد critical section شون بشن و الان اون منبع ازاد هست پروسس جدیدمون نتونه وارد critical section اش بشه 3- Bounded Waiting: اینطور نباشه که روش ما جوری نوشته شده باشه که پروسس ها برای وارد

شن به critical section شون مقدار زمان نامحدودی رو بخوان صبر کنن برای ورود به critical section پس ما انتظار داریم که هر پروسسی اگر مایل بود وارد critical section بشه یک زمان

محدودی رو منتظر بمونه و بعد دیگه یه جوری بهش نوبت و اجازه داده بشه که وارد critical section اش بشه پس باید یک باندی روی اون زمانی که پروسس منتظر می مونه که وارد critical section اش بشه و جو د داشته باشه

و این دوتا مورد رو توی این قسمت باید در نظر بگیریم: 1- همه پروسس ها به هر جال اجرا میشن ینی مثلا اگر n تا پروسس داریم به هر حال این ها زمان بندی می شن و یه موقعی هر کدومشون اجرا میشن پس باید یه همچین فرضی رو داشته باشیم وقتی می خوایم

Bounded Waiting رو چک بکنیم 2- هیچ فرضی برای اینکه بدونیم به چه نسبت و با چه سرعتی این ها دارن بین هم اجرا میشن یا زمان بندیشون به چه نسبته نخواهیم داشت توی همه حالات باید این Bounded Waiting رعایت بشه مثلا p1

یک پروسه ی با اولویت بالا باشه بنابراین تعداد دفعاتی که اجرا میشه و میخواد وارد critical section اش بشه زیاده و اسکجولر سیستم هم خیلی اینو اسکجولش میکنه توی یک زمان مشخصی ولی مثلا p5 اولویت پایینی داره و گهگاهی اجرا بشه ولی بلاخره اجرا میشه

این شرط سوم به دوتا شرط شکسته میشه: 1- عدم گرسنگی 2- عدم بن بست ینی اگر ما بن بست و گرسنگی نداشته باشیم شرط Bounded Waiting رعایت شده و اگر هر کدوم از این ها پیش بیاد این شرط نقض شده

پس باید 4 تا مورد رو برای مسئله چک بکنیم

Definitions

- Tritical resource (منبع بسحرانیی): a shared resource between more than one threads (processes) that can not be used or updated concurrently by them.
- Critical section (ناحیه بسحرانیی): a section of code for updating a critical resource. Ex: write to printer buffer, updating a table in database, writing to a file
- Race condition (شرايط رقا بستى): a situation where several processes access and manipulate the same data (a critical resource) concurrently.
- Synchronization (همگام سانی): Orderly execution of cooperating processes that share a critical resource
- Deadlock (بسن بسست): two or more processes are blocked with each other to enter the critical section and progress execution.
- Starvation (کسرسنگی): a process wait indefinitely for entering the critical section

Critical resource: منظور همون ریسورس شیری است که چندتا پروسس یا ترد دارن همزمان ازش استفاده می کنن یا اپدیتش می کنن ازش استفاده می کنن یا اپدیتش می کنن Critical section: اون قسمت کدی است که اون Critical resource رو توی این داریم تغییر

میدیم یا داریم ازش استفاده میکنیم Race condition: اگر اجرای پروسس ها یا تردها به نحوی صورت بگیره که حداقل دوتاشون بتونن همزمان به اون قسمت Critical section برسن اون وقت شرایط رقابتی پیش میاد Synchronization: راه حلمون برای حل مسئله Critical section است ینی ما میخوایم برای

بنوس همرهان به اون قسمت Critical section براس اون وقت سرایط رفایتی پیش میاد Synchronization: راه حلمون برای حل مسئله Critical section است ینی ما میخوایم برای اینکه مطمئن بشیم این ها همزمان وارد Critical section شون نمی شن از همگام سازی استفاده بکنیم ینی به نوعی ترتیب بدیم به اجرای اون پروسس هایی که دارن یک منبع مشترک رو استفاده می کنن و با ترتیب اجرا وارد Critical sectionشون بشن که مطمئن بشیم هیچ وقت همزمان

وارد نمیشن Deadlock: شرایطی پیش بیاد که دو یا تعداد بیشتری پروسس به جایی برسن که میخوان وارد Deadlock: شرایطی پیش بیاد که دو یا تعداد بیشتری پروسس به جایی برسن که میخوان وارد Critical sectionشون بشن ولی ما راه حلمون یه جوری بوده که هیچکدومشون نمی تونن وارد Critical sectiorشون بشن و تا ابد توی نقطه entry می مونن در این حالت می گیم بن بست پیش

اومده - ممکنه اگر n تا پروسس داریم برای دوتا از پروسس ها این مشکل پیش بیاد در این حالت بازم ما راه حلمون منجر به بن بست شده پس اگر دوتا یا تعداد بیشتری از پروسس ها به نقطه entry برسن و هیچکدوم نتونن وارد Critical sectionشون بشن این حالت بن بست است Starvation: ینی حالتی پیش بیاد که پروسس p1, p2 ما مدام از Critical section بتونن استفاده بکنن و لی مده بنی حوری نست که

Starvation: یسی حالتی پیش بیاد که پروسس P1, p2 ما مدام از Critical section بنون استفاده بکنن ولی p3 هیچ وقت نتونه استفاده بکنه اینجا بن بست پیش نیومده ینی جوری نیست که این ها نتونن برن جلو ولی گرسنگی پیش اومده ینی p3 نتونسته ریسورس بگیره ولی p1, p2 تونستن جلو برن

Critical-Section Handling in OS

Two approaches depending on if kernel is preemptive or nonpreemptive

- allows قبضه شدنی یا غیرلنحصاری Preemptive allows allows
- runs until حقیضه نشدنی یا ۱ نیحصاری Non-preemptive runs until exits kernel mode, blocks, or voluntarily yields CPU
 - Essentially free of race conditions in kernel mode
- preemptive kernels are difficult to design especially in SMP (Symmetric Multi-Processing), but they are more responsive and suitable for real-time

یکی از راه حل هایی که عنوان میشه برای حل مسئله Critical-Section راه حلی است برای سیستم عامل فرض کنیم داریم انتخاب می کنیم این راه حل رو پنی برای کرنل سیستم عامل پنی حالتي كه ما وقفه ها رو بخوايم غيرفعالش بكنيم

سيستم عامل كلا Interrupt-based است بقيش صفحه بعد... این صفحه...

کرنل رو دو دسته کرده:

1- یک حالت این که کرنل Preemptive باشه ینی ما اجازه داریم وقتی که یک کدی داره توی

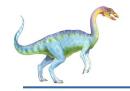
کرنل اجرا میشه cpu رو ازش بگیریم و یک کد دیگه ای رو اجرا بکنیم 2- وقتى كه داريم وقفه ها رو غير فعال ميكنيم يني اين كه داريم كرنل رو Non-preemptive میکنیم پس غیرفعال کردن وقفه ها ینی ما داریم کرنل رو Non-preemptive می کنیم ینی وقتی

که یک کدی داره توی کرنل اجرا میشه ما هیچ وقت ازش cpu رو نمی گیریم مگر اینکه خودش

اگر اینطوری باشه شرایط رقابت هچ وقت توی کرنل پیش نمیاد و مسئله ما حل شده در حالت کلی Preemptive کرنل ها مناسب تر هستند برای وقتی که سیستممون قراره که پاسخگوییش بالا باشه یا ریل تایم باشه اما مشکل اون مدیریت اون Critical-Section رو اینجا

بلاک بشه یا خودش cpu رو پس بده ینی اجراش تموم شده

خواهیم داشت مخصوصا وقتی که سیستممون SMP است در واقع خیلی سخت میشه مدیریت Critical-Section



Interrupt-based Solution

- Entry section: disable interrupts
- Exit section: enable interrupts
- Will this solve the problem?
 - What if the critical section is code that runs for an hour?
 - Can some processes starve never enter their critical section.
 - What if there are two CPUs?



ینی اگر ما مطمئن باشیم که وقتی که داره یک تیکه کد اجرا میشه وقفه پیش نمیاد راهی برای گرفتن cpu از این تیکه کد وجود نداره مثلا p1 داره اجرا میشه توی کرنل ما وقفه ای هم نداریم خب این باید اونقدر اجرا بشه که دیگه اجراش تموم بشه پنی دیگه خودش ادامه ای نداشته باشه و

رسیده باشه به تهش در این صورت هیچ وقت همزمانی بین دوتا پروسسی یا دوتردی که توی سطح

کرنل دارن اجرا میشن پیش نمیاد پس چون همزمانی پیش نمیاد پس مشکلی هم پیش نمیاد پس یکی از راه حل هایی خیلی ساده اینه که ما وقفه هایی سیستم رو وقتی که یک پروسس میخواد وارد

critical sectionاش بشه غیر فعال بکنیم یا به طور کلی بگیم وقتی که یک فانکشنی یا یک سیستم

کالی توی کرنل داره اجرا میشه همون ابتدا ما کلا وقفه ها رو غیر فعال میکنیم که مطمئن بشیم که

فانکشن دیگه همزمان نمی تونه اجرا بشه

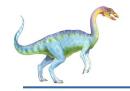
مشکل اولیه که این داره اینه که مثلا پروسس p1 برای زمان طولانی بخواد اجرا بشه که این خیلی

بده چون کل cpu رو دادیم به این پروسس و هیچ کد دیگه ای توی کرنل نمیتونه اجرا بشه وقتی که این داره اجرا و این باعث میشه که بقیه پروسس ها به گرسنگی بخورن

مسئله بعدی هم اینه که ما دوتا cpu داریم اگر دوتا cpu داشته باشیم این غیرفعال کردن وقفه ینی وقفه های هر دوتا cpu رو غیرفعال بکنیم و اگر مثلا اگر p1 داره توی cpu یک اجرا میشه هیچ

کد دیگه ای نباید روی Cpu های دیگه هم بتونن اجرا بشن پس وقفه های اونا هم باید غیرفعال بکنه و برای همچین کاری ار تباطی بین این cpu ها نیازه که خود این زمان بر است و یه مقدار این کار،

کار سختی است که ما بخوایم همزمان بخوایم وقفه های همه cpu های سیستم رو غیر فعال بکنیم



Software Solution 1

- Two process solution
- Assume that the load and store machine-language instructions are atomic; that is, cannot be interrupted
- The two processes share one variable:
 - int turn;
- The variable **turn** indicates whose turn it is to enter the critical section
- initially, the value of turn is set to i



راه حلى كه تا اينجا گفتيم يك راه حل سخت افزاري بود البته مسئله رو حل ميكرد و البته می تونست تا حدی گرسنگی ایجاد بکنه و پیاده سازیش هم سخت بود و پاسخگویی سیستم رو هم

section و یه جورایی توی کدی که داریم می نویسیم پنی همون جایی که کدهای برنامه رو می

نویسیم که ممکنه توی شرایط رقابتی قرار بگیرند اونجاها یه جوری کدشو بنویسیم که بهشون ترتیب

اجرا بدیم ینی برای ورودشون به critical section یه جوری ترتیب اعمال بکنیم که مطمئن بشیم

همزمان وارد اون critical section نمیشن و دوتا شرط دیگه ای که برای مسئله critical

یک متغییر turn تعریف میکنیم توی کدمون و با استفاده از ست کردن مقدار turn سعی میکنیم

جوری این turn رو مقدار دهی بکنیم که مطمئن بشیم فقط یکی از پروسس ها وارد

section رو هم گفتیم رو دارن

section میشه

ایا می تونیم ترفند هایی توی نرم افزار داشته باشیم که اونجا جلوگیری بکنیم از پیش اومدن critical

میاورد پایین



Algorithm for Process P_i

```
while (true) {
   while (turn = = j);
   /* critical section */
   turn = j;
   /* remainder section */
```

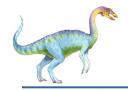


این روش نایس برخورد میکنه ینی همیشه نوبت رو میده به پروسس مقابل مثلا اگر ما پروسس pi , pi رو داشته باشیم پروسس pi همیشه قبل از ورود به critical section چک میکنه که نوبت j هست یا نه و اگر نوبت j بود وارد critical section نمیشه و توی حلقه چک کردن j می مونه اینقدر تا اون یکی پروسس از critical section در بیاد و بعد این یکی بتونه وار د بشه همین کد رو برای پروسس j داریم و برای turn==i داره صبر میکنه بعد critical section هم توی نقطه exit یک eturn=j گذاشتیم ینی اگر پروسسی وارد section اش شد و کدهاشو اجرا کرد توی این قسمت و چون دیگه کاری نداره توی critical section نوبت رو میده به طرق مقابل و اگر طرف مقابلی توی این خط while اش مونده باشه می تونه رد بشه و وارد critical sectionاش بشه همین کدو که این طرف برای i داریم اون طرف هم برای j هم داریم هیچ وقت هر دو نمی تونن همزمان وارد critical section بشن چون این turn یا برابره با i است یا i منظورم توی حلقس چک کردن شرط Progress: فرض کنید pi اومده باشه و رفته باشه توی critical section اش

و pj هم اصلا توی این حلقه اولی که critical section نیست یا قبلشه یا بعدشه در کل pj اصلا نمیشه در الان وارد critical section اش بشه در این حالت pj وارد critical section اش میشه و بعد از اینکه خارج شد turn=j میکنه ینی نوبت رو می ده به j و gi نمی خواد وارد turn=j اینکه خارج شد section میکنه و pi میاد section. اش رو اجرا میکنه و برمیگرده و دوباره ممکنه برای دفعه بعدی بخواد وارد critical section اش بشه اینجا چک میکنه و می بینه j== turn= هست یا نه که خودش قبلا مساوی j کرده ولی اون یکی پروسس نخواسته اصلا استفاده بکنه پس این پروسس i pi اینجا توی این حلقه می مونه ینی j== turn و هر چی هم صبر بکنه دیگه هیچ وقت از این خط نمی تونه رد بشه چون pj دوست نداشته که وارد critical مسبر بکنه دیگه هیچ وقت از این خط نمی تونه رد بشه چون pj دوست نداشته که وارد critical بیس دوش ما توی این حالت مانع ورود pi به section میشه پس کلا روشمون روش درستی نیست

چک کردن شرط Bounded Waiting: بن بست هیچ وقت پیش نمیاد - گرسنگی نداریم چون

نوبت داره جابه جا میشه همش پس گرسنگی هیچ وقت نداریم



Correctness of the Software Solution

Mutual exclusion is preserved

P_i enters critical section only if:

turn = i

and turn cannot be both 0 and 1 at the same time

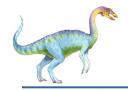
- What about the Progress requirement?
- What about the Bounded-waiting requirement?



نكته:

خود روش داره از یک متغییر شیری باز استفاده میکنه مثلا turn اینجا شیر بود بین دوتا پروسس و

تغییر مقدار turn دوباره اینجا باید حواسمون بهش باشه که مسئله همزمانی رو نداشته باشه



Peterson's Solution

- Two process solution
- Assume that the load and store machine-language instructions are atomic; that is, cannot be interrupted
- The two processes share two variables:
 - int turn;
 - boolean flag[2]
- The variable turn indicates whose turn it is to enter the critical section
- The flag array is used to indicate if a process is ready to enter the critical section.
 - flag[i] = true implies that process P_i is ready!



راہ حل Peterson:

Algorithm for Process P_i and P_j

P_i F

```
do {
   flag[i] = true;
   turn = j;
   while (flag[j] && turn == j);
     critical section
   flag[i] = false;
     remainder section
} while (true);
```

```
do {
   flag[j] = true;
   turn = i;
   while (flag[i] && turn == i);
     critical section
   flag[j] = false;
   remainder section
} while (true);
```



ر وش بنر سون: این میاد مشکل روش قبلی رو حل میکنه ینی Progress نداره اینجا بیایم چک بکنیم که طرف مقابل دوست داره که وارد critical section بشه یا نه و اگه دوست نداشت بیایم نوبتی که به اون دادیم رو پس بگیریم برای این کار پترسون میاد از یک فلگ استفاده مىكنە هر پروسسی یک فلگ برای خودش داره و اگه فلگ خودش رو true کرد پنی دوست داره که وارد critical section اش بشه و اگه False بو د بنی دو ست ندار ه پس اینجا مثل همون روش قبلی است فقط یک فلگ داریم اینجا وقتی که یک پروسسی critical section اش رو تموم کرد میاد فلگش رو False می کنه که یک يروسس ديگه نمونه پشت critical section خودش شرط اول: برقرار است چون ما اینجا داریم turn رو چک میکنیم و turn مقدارش یا i است یا j یس فقط یکی از این پروسس ها وارد critical section اش میشه شرط دوم: با اضافه کردن این فلگ progress حل شده پس برقرار است

شرط سوم: بن بست نداریم بخاطر این متغییر turn حالتی پیش نمیاد که دوتایشون پشت این while داخلی بمونن چون turn بلاخره یا i است یا j پس بن بست نداریم

برای چک کردن گرسنگی یکی از کار هایی که باید بکنیم اینه که سرعت اجرای این دوتا پروسس رو به نسبت هم تغییر بدیم پنی اسکجولر هی به یکیشون نوبت بده و به یکی دیگه نده و تک پروسسور هم

در نظر بگیریم و کار کنیم چون اگر دو تا پروسسوره کار کنیم معمولاً گرسنگی بیش نمیاد چون به محض اینکه پروسس اول از critical section خارج شد پروسس دوم می تونه کدش رو اجرا بکنه و وارد بشه پس وقتی که می خوایم شرایط گرسنگی رو پدید بیاریم با یه دونه پروسسور کار بکنیم و تایم شیرینگ بین این دوتا داشته باشیم و به یکی هی بیشتر زمان بدیم توی این مثال گرسنگی هیچ وقت نداریم اگه چک

بکنیم چون اگر این پروسس یک وارد critical section اش بشه و بعد خارج بشه و فلگش رو False بکنه و j هم بخواد وارد بشه ینی فلگ j اینجا true میشه و وقتی که پروسس j به حلقه می رسه و چون نوبت j میشه cpu به اون داده میشه پس در هیچ حالتی اینجا ما گرسنگی نداریم مثلا زمانی گرسنگی داریم که j بخواد وارد بشه ولی هیچ وقت بهش cpu داده نشه

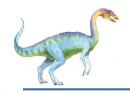
Peterson's Solution (Cont.)

- Provable that the three CS requirement are met:
 - 1. Mutual exclusion is preserved

```
P<sub>i</sub> enters CS only if:
  either flag[j] = false Or turn = i
```

- 2. Progress requirement is satisfied after critical section flag[i] set to be false
- Bounded-waiting requirement is met it is achieved through setting turn correctly
- Peterson's solution is not guaranteed to work on modern computer architectures
 - Because of reordering read and write operations that have no dependencies

توی کامپیوتر های مدرن امروزی بازم یک مسئله ای داریم که این روش نرم افزاری پترسون هم ممكنه دچار مشكل بشه اون مسئله reordering read and write operations است مثالش صفحه 24..



Peterson's Solution and Modern Architecture

- Although useful for demonstrating an algorithm, Peterson's Solution is not guaranteed to work on modern architectures.
 - To improve performance, processors and/or compilers may reorder operations that have no dependencies
- Understanding why it will not work is useful for better understanding race conditions.
- For single-threaded this is ok as the result will always be the same.
- For multithreaded the reordering may produce inconsistent or unexpected results!



-

اجر ا میکنه

پس مسئله reordering این است که توی سیستم های مدرن برای اینکه پرفرمنس بالا بره گاهی

اوقات پروسسور یا کامپایلر میاد دو تا خطی که اجراشون توی حافظه ربطی بهم نداره رو جابه جا

این reordering توی یک پروسسور سینگل ترد مشکلی ایجاد نمیکنه ولی اگه مالتی ترد باشه می

تونه مشکل ایجاد بکنه که مسئله های ما توی critical section هم مسائل مالتی ترد است



Modern Architecture Example

Two threads share the data:

```
boolean flag = false; int x = 0;
```

Thread 1 performs

```
while (!flag)
;
print x
```

Thread 2 performs

```
x = 100; flag = true
```

What is the expected output?

100



توی کامپیوتر های مدرن یک اتفاقی که می افته اینه که اون خطوطی که داره اجرا میشه توی cpu و اگر مربوط به دسترسی به حافظه باشه اون خطوط اگر اون حافظه که داره بررسی میشه مثلا اینجا داره مقدار فلگ رو اپدیت میکنه و بعد مقدار x را و x و فلگ دوتا مقدار متفاوت هستند ینی توی

بکنه اگر این اتفاق بیوفته توی برنامه های مالتی ترد از جمله جاهایی که شیرد مموری داریم ممکنه که دچار مشکل بشیم حتی اگر راه حل نرم افزاری مثل پترسون رو به کار برده باشیم بقیش صفحه قبلی..

مموری بهم ربطی ندارند در این حالت cpu ممکنه به دلایلی این دوتا خط رو جابه جا بکنه و اجرا

مثال: ترد یک داره یک فلگی رو چک میکنه و وقتی که فلگ true شد می تونه به خط print x برسه و

بعد x رو 100 می کنه و بعد فلگ رو true میکنه اگر reordering پیش بیاد مقدار x چند میشه؟ ینی جای x=100 با جای flag = true می تونه

جابه جا بشه در این حالت اگر ترد دو در حال اجرا بوده و فلگش رو true بکنه و بعد cpu قبل از اینکه x بیاد و 100 بشه به ترد یک داده بشه در این حالت حلقه رو رد میکنه و مقدار x رو برابر با

صفر چاپ میکنه و بعد cpu داده میشه به ترد دوم و مقدار x رو 100 می کنه در حالی که ما انتظار داشتیم جواب نهایی خروجی بشه 100 نه صفر پس reordering اینجا باعث شد که توی اون مقدار ها یک مشکلی به وجود بیاد وقتی که مالتی ترد است



Modern Architecture Example (Cont.)

However, since the variables flag and x are independent of each other, the instructions:

```
flag = true; x = 100;
```

for Thread 2 may be reordered

If this occurs, the output may be 0!



Reordering problem for peterson

```
boolean flag = false;
                int x = 0;
                                               Thread 2
  Thread 1
while (!flag)
                                               x = 100;
print x;
                                               flag = true;
process_0 \longrightarrow turn = 1
                                        → flag[0] = true | → cs §
process _1 \longrightarrow turn = 0 , flag[1] = true \longrightarrow
                             time
```

This allows both processes to be in their critical section at the same time!

To ensure that Peterson's solution will work correctly on modern computer architecture we must use **Memory Barrier**.

_

مثلا reordering توی روش پترسون:



Memory Barrier

How a computer architecture determines what memory guarantees it will provide to an application program is known as its **memory model**

- Memory models may be either:
 - Strongly ordered where a memory modification of one processor is immediately visible to all other processors.
 - Weakly ordered where a memory modification of one processor may not be immediately visible to all other processors.
- A memory barrier is an instruction that forces any change in memory to be propagated (made visible) to all other processors.



یکی از روش های حل مسئله Reordering امکانی که توی سیستم ها قرار دادن که بهش Memory Barrier گفته میشه سیستم ها از لحاظ مدل مموری دو نوع می تونن باشن:

Strongly ordered: ینی سیستم هایی که سیمتریک مالتی پروسسور هستند و تغییراتی که هر پروسسور روی حافظه انجام میده اگه سریعا توسط پروسسور های دیگه قابل دیدن باشه بهش میگیم

Strongly ordered ینی خود سیستم داره سیاستی رو اعمال میکنه که هر تغییری توی مموری با

استفاده از یک cpu رخ داد cpu های دیگه هم فوری این تغییر رو ببینن

Weakly ordered: وقتی هست که تغییرات مموری از یک پروسسور ممکنه بلافاصله توسط

پروسسور های دیگه درک نشه و اگر یک سیستمی Weakly ordered باشه ممکنه در بعضی

مواقع مشكلاتي ايجاد بشه و راه حلى كه براش ارائه مي كنن Memory Barrier هست

Memory Barrier در واقع مجبور میکنه سیستم رو که تغییراتی که توی مموری هرجا انجام

میشه به بقیه پروسسور ها حتما اعلام بشه و منتشر بشه



Memory Barrier Instructions

- When a memory barrier instruction is performed, the system ensures that all loads and stores are completed before any subsequent load or store operations are performed.
- Therefore, even if instructions were reordered, the memory barrier ensures that the store operations are completed in memory and visible to other processors before future load or store operations are performed.



بنابراین اگر ما یک دستور Memory Barrier داشته باشیم و یک دستور اجرا بشه سیستم می تونه مطمئن باشه که load and stores ها به صورت کامل قبل از اینکه

قابل دیدن است قبل از اینکه loads and stores آیرشن های دیگه انجام بشه

بریم سراغ قسمت دیگه ای از مموری انجام میشه پس اگر ما Memory Barrier داشته باشیم می تونیم مطمئن باشیم که هر loads and stores که داریم کامل انجام میشه و بعد loads and stores بعدی انجام میشه

پس حتى اگر دستور ها reordered بشن Memory Barrier تضمین میکنه که عملیات store کامل انجام میشه توی مموری و توسط بقیه پروسسور ها هم بلافاصله بعد از اینکه store انجام شد



Memory Barrier Example

- Returning to the example of slides 6.24 6.25
- We could add a memory barrier to the following instructions to ensure Thread 1 outputs 100:
- Thread 1 now performs

```
while (!flag)
  memory_barrier();
print x
```

Thread 2 now performs

```
x = 100;
memory_barrier();
flag = true
```

- For Thread 1 we are guaranteed that that the value of flag is loaded before the value of x.
- For Thread 2 we ensure that the assignment to x occurs before the assignment flag.



مثال:

اینجا قبل از دسترسی به X اگر ما دستور Memory Barrier بذاریم اینطوری مطمئن میشیم که تا این خط دستور Memory Barrier هر کدی که داریم loads and stores کامل شده و بعد می

ره سراغ بعدی پس اینجا دیگه اون reordered اعمال نمیشه به طوری که مشکلی ایجاد بکنه

یا توی قسمت یایین اول مقدار x به طور کامل ذخیره میشه و بعد دستور بعد x با توی قسمت یایین اول مقدار

انجام میشه بخاطر این Memory Barrier که اینجا گذاشتیم

Check Critical section requirements

```
P1:
                                              P2:
while (true) {
                                               while (true) {
     flag [1] = true ;
                                                  flag [2] = true;
     turn = 1;
                                                  turn = 2;
     while (flag [2] and turn=2);
                                                   while (flag [1] and turn=1);
     <Critical - Section >
                                                        < Critical - Section >
    flag [1] = false ;
                                                   flag [2] = false;
    < remainder >
                                                   < remainder >
```

تمرین: هر سه تا شرط رو برای مثال چک بکنیم

این شرط اول رو نقض میکنه درست میگم؟؟؟؟



Synchronization Hardware

- Many systems provide hardware support for implementing the critical section code.
- Uniprocessors could disable interrupts
 - Currently running code would execute without preemption
 - Generally too inefficient on multiprocessor systems
 - Operating systems using this not broadly scalable
- We will look at three forms of hardware support:
 - 1. Hardware instructions
 - Atomic variables



روش های که در اختیار دولویرها قرار گرفته برای حل مسئله critical section که همه اون ها مبتنی بر روش های سخت افز اری هست قبلا یک روش گفتیم: گفتیم که توی سیستم های تک پروسسوره می تونیم وقفه ها رو غیرفعال بکنیم

توی اون قسمت critical section یا وقتی که یک کد کرنل داره اجرا میشه وقفه ها غیر فعال بشه

و به این صورت مطمئن میشیم اون قسمت کد کامل اجرا خواهد شد و بینابین دستوراتش کد دیگه ای نمی تونه اجرا بشه توی سیستم های تک پروسسوره اعمال چنین روشی راحت بود ولی اگر سیستم مالتی پروسسور بود این کار موثر نبود و overhead داشتیم برای غیرفعال کردن وقفه های cpu های دیگه پس این روش توی هر نوع سیستمی قابل استفاده نیست پس روش های دیگه ای ار ائه شد:

Hardware instructions .1

Atomic variables .2



Hardware Instructions

- Special hardware instructions that allow us to either test-and-modify the content of a word, or to swap the contents of two words atomically (uninterruptedly.)
 - Test-and-Set instruction: Either test memory word and set value
 - Compare-and-Swap instruction: Or swap contents of two memory words



دستورات سخت افزاری که در واقع سیستم ها در اختیار ما قرار میدن که از طریقش بتونیم قسمت بحرانی رو مدیریت بکنیم:

:Test-and-Set

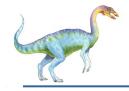
Compare-and-Swap هم به همین صورت

:Compare-and-Swap

مطمئن هستیم که وقتی بدنه ی هر کدوم از این دستورات بنی Test and set و compare and swap داره اجرا میشه اون دستور دیگه یه جوری مثل یک بلاکه و uninterruptedly ینی این

test and set دیگه مثل یک فانکشنی نیست که مثلا ممکنه که وسط اجرای یک فانکشن وقفه بخوره و پروسس دیگه ای اجرا بشه مطمئنیم که کل این بدنه Test-and-Set بدون وقفه اجرا

میشه و هیچ دوتا Test-and-Set روی یک متغییری نمی تونن همزمان اجرا بشن و برای



The test_and_set Instruction

Definition

```
boolean test_and_set (boolean *target)
{
    boolean rv = *target;
    *target = true;
    return rv:
}
```

- Properties
 - Executed atomically
 - Returns the original value of passed parameter
 - Set the new value of passed parameter to true



مثال-

اگر مقدارش قبلا توسط یک بروسس دیگه ای true شده بود پنی قبلا این test and set یک جایی فراخوانی شده بود برای همین متغییر و این متغییر رو trrue کرده بوده می خوایم بفهمیم این اتفاق افتاده است یا نه؟ برای همین مقدار قبلی این متغییر رو نگهداری میکنیم توی یک temp و

یک مقدار بولین میگیره و بعد سعی میکنه مقدار این بولین رو true کنه

اون رو ریترن می کنیم توسط این فانکشن test_and_set برای همین همیشه این مقدار target

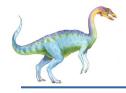
رو true می کنیم این ریترن کردن به چه دردی می خوره؟ چون ما بعد از فراخوانی این تابع test_and_set می

تونیم چک بکنیم این مقداری که ریترن شده True است یا نه و اگر مقدارش true باشه می فهمیم قبلاً کسی اینو true کرده بوده و این ما نبودیم که اینو true کردیم پس بخش بحرانی رو نمی گیریم پس می تونیم اینطوری در نظر بگیریم که این مثل یک قفلی است که دست ما است و قبلا اون

متغییره قفل شده توسط کس دیگه ای پس ما دیگه نمی تونیم اینجا کاری بکنیم ولی اگر این مقدار false بود پس مقدار rv میشه false و ما مقدار target رو true میکنیم و مقداری که این فانکشن برمی گردونه false است و می فهمیم این ماییم که این متغییر رو

وبڑگی هاش: این قطعه کد به صورت اتمیک اجرا میشه --> اتمیک پنی همون بدون وقفه original value اون پار امتری که بهش دادیم رو بهمون برمی گردونه برای اینکه بفهمیم این جدید

True شده یا قبلا کسی اینو true کرده و همیشه هم ما میخوایم این متغییر رو true بکنیم با این فانکشن



Solution Using test_and_set()

- Shared boolean variable lock, initialized to false
- Solution:

Does it solve the critical-section problem?

This solution does not satisfy bounded waiting: starvation



While(lock==true);

lock=true:

و ار د بک بخش بحر انی بشن اگر کسی این lock رو خودش true کرد می تونه وارد بخش بحرانی بشه و تا زمانی که true

است کس دیگه ای نمی تو نه و ار د بخش بحر انیش بشه بنابر این مقدار او لیه این متغییر باید false

فرض کنید یک متغییر lock می خوایم داشته باشیم که این شیر است بین پروسس هایی که میخوان

ىاشە یس هر کسی می خواد وارد بخش بحرانیش بشه این lock رو true میکنه و کسی هم که میخواد

و ار د بشه باید چک بکنه که قبلا این True نشده باشه --> کد ابیه میشه

و وقتی که وار د بخش بحر انی شد بعد بعدش lock رو false بکنه و اینجا که False اش کر د اگر کسی دیگه ای پشت این حلقه while موند بود می تونه وار د بخش بحرانی بشه

یس روش ما به طور کلی با استفاده از یک متغییر lock به این صورت است

البته این روش ساده یک مشکلی داره: همزمان اگر توی دونا پروسس این اجرا بشه دونا پروسس می

تونن همزمان بعد از اینکه lock ما false بود توی حلقه lock رو چک بکنن و هر دوشون

می بینن lock ما False است پس از حلقه رد می شن و lock رو true می کنن و فکر می کنن

خودشون true کر دن و وار د بخش بحر انیشون می شن هر دو --> پس این روش دقیق و در ستی نبست

ادامش صفحه بعدي ...

حالا میخوایم این روش رو درست بکنیم: با استفاده از test_and_set این کارو میکنیم --> اینجا به جای اینکه این شرط رو روی lock با استفاده از حلقه چک بکنیم از یک test and set استفاده میکنیم به این صورت که: تا زمانی که test and set --> lock ما true هست صبر کن این ینی اگر کسی قبلا lock رو true کرده ما باید منتظر بمونیم و نمی تونیم وارد بخش بحرانی بشیم --> اینجا دیگه مطمئن هستیم این دستور test_and_set روی lock فقط توسط یک پروسس در یک لحظه اجرا میشه ینی حتی اگر سیستمون چند پروسسور باشه این test and set روی

این lock نمی تونه روی دوتا بروسسور همزمان اجرا بشه پس این دیگه مثل اون حلقه while نیست و مشکل قبلی رفع میشه بعد به محض اینکه یک پروسسی بخش بحرانیش تموم شد lock اش رو false میکنه و به محض

اینکه false شد یکی از این پروسس هایی که داره این تابع test_and_set رو فراخوانی میکنه موفق میشه که lock رو خودش true بکنه و مقدار قبلیش هم که False بوده که ریترن میشه پس

از این حلقه خارج میشه

ایا این کامل کامل داره در ست کار میکنه یا نه ؟ از لحاظ شرط اول اره --> چون بلاخره مقداری که حلقه برمیگر دونه یا false است یا true و تا

وقتی که true است کس دیگه ای نمی تونه وارد بخش بحرانی بشه شرط دوم هم برقراره شرط سوم: در مورد مسئله بن بست ینی دو تا پروسس پشت حلقه گیر بکنند و نتونن رد بشن هیچ

وقت پیش نمیاد این حالت بخاطر اینکه فقط یک پروسس است که میتونه این lock رو true بکنه و این همیشه یک مقداری رو برمیگردونه و هیچ وقت شرایطی پیش نمیاد که دوتا پروسس اینجا بمونن و هیچ وقت رد نشن

ادامشش___

بکنه ولی هنوز lock رو false اش نکرده بعد cpu رو میدیم به p2 و p2 الان چک میکنه این lock ما lock ما است یا False است و می بینه این true است و اجرا نمیشه و هرچقدر هم این test_and_set اجرا بکنه توی این حلقه ینی هی cpu داریم بهش میدیم که این test_and_set رو چک بکنه بازم نمیتونه وارد بشه و یک عالمه بار اینو اجرا میکنه و وقتی که تایم اسلایس این false روسس تموم شد باید cpu رو پس بده و cpu پس داده میشه به p1 و p1 میاد pol رو همچنان میکنه و ممکنه که دوباره بیاد سر خط while و بخواد دوباره وارد بخش بحر انیش بشه و همچنان cpu دستش است و چون مقدار قبلی lock ما False است می تونه وارد بشه و بره توی بخش cpu

علت این بخاطر نوع پیاده سازی است که اینجا داریم ینی ما cpu را اینجا مشغول کردیم در حالتی

بحرانی و دوباره بدیم cpu به p2 و دوباره مثل قبل است این پس گرسنگی داریم اینجا

که توی حالت wait هستیم و هیچ نتیجه خوبی نداره این کار

مسئله گرسنگی: ینی شرایطی پیش میاد که اگر ما دوتا پروسس داریم یکی از پروسس ها مدام از این

بخش بحرانی استفاده بکنه و یکی دیگه نتونه وارد بشه --> توی سیستم تک پروسسوره اینو بررسی

میکنیم--> توی یک سیستم تک پروسسوره فرض می کنیم یک پروسسی وارد بخش بحرانیش شده ویروسس دوم توی این حلقه اولش مونده و چون تک پروسسوره هستیم و p1 داخل بخش بحرانیش

است هیچی از p2 اجرا نمیشه ینی حتی نمی تونه این مقدار test and set رو چک بکنه -->

بخش بحرانی p1 تموم می شه و کامل اجرا میشه می رسه به این خطی که باید lock رو false اش



The compare_and_swap Instruction

Definition

```
int compare_and_swap(int *value, int expected, int new_value)
{
  int temp = *value;
  if (*value == expected)
      *value = new_value;
    return temp;
}
```

- Properties
 - Executed atomically
 - Returns the original value of passed parameter value
 - Set the variable value the value of the passed parameter
 new_value but only if *value == expected is true. That is, the
 swap takes place only under this condition.

Intel x86 instruction cmpxchg <destination operand>, <source operand>



compare_and_swap هم خیلی شبیه test and set است با این تفاوت که کاری که داره

انجام میده اینه که مقدار یک متغییری رو میخواد عوض بکنه پنی value با مقداری که ما داریم مشخص میکنیم ینی new_value ولی فقط در صورتی این new_value رو ست میکنه که

مقدار value قبلاً با این مقدار expected بر ابر باشه پنی در صورتی مقدار value رو تغییر میده که به مقدار new value که مقدار قبلی value برابر باشه با expected

از ادی عمل با این بیشتر است

قر ار گرفته باشه

نمونه این دستور هم توی intel x86 است

شرایط مثل قبلی است ینی اتومیک است و مقدار original value متغییر value هم ریترن میشه و فقط در صورتی مقدار Value ایدیت میشه که مقداری که قبلاش بهش دادیم توی این value



Solution using compare_and_swap

- Shared integer lock initialized to 0;
- Solution:

```
while (true) {
    while (compare_and_swap(&lock, 0, 1) != 0)
    ; /* do nothing */

    /* critical section */

    lock = 0;

/* remainder section */
}
```

Does it solve the critical-section problem?

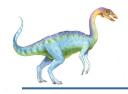


-مثال:

مونه

مقدار قبلی lock است که اگر صفر بود از حلقه رد میشه و تا وقتی که صفر نیست توی حلقه می

منطق این مثل روش test and set است پس این روش هم همون مشکل گرسنگی رو داره



Bounded-waiting with compare-and-swap

```
while (true) {
   waiting[i] = true;
   key = 1;
   while (waiting[i] && key == 1)
      key = compare and swap(&lock,0,1);
   waiting[i] = false;
   /* critical section */
   i = (i + 1) % n;
   while ((j != i) && !waiting[j])
      i = (i + 1) % n;
   if (j == i)
      lock = 0;
   else
      waiting[j] = false;
   /* remainder section */
```



برای حل مسئله که باعث گرسنگی نشه می تونیم یه کاری رو انجام بدیم: هر جا که گرسنگی بود برای اینکه گرسنگی نباشه و زمانی که یک ریسورس محدودی داریم باید

روش: اگر n تا پروسس داشته باشیم هر دفعه نوبت به یکیشون برسه مثلا اگر n تا داریم از 0 تا n نوبت

بدیم و اگر صفر اجرا شد دیگه دفعه بعدی نتونه اجرا بشه اگر مثلا 1 یا بقیشون می خواستن وارد

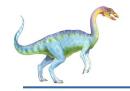
بشن و این کار رو با یک waiting[i] مشخص میکنیم مثل همون روش پترسون است

میایم true] رو true میکنیم و اگر این ها هر کدوم مایل بودن و نوبتشون رسید اجازه میدیم وارد بشن و این lock رو با همون compare-and-swap داره استفاده میکنه تا مسئله اش از

طریق سخت افزار حل شده باشه

و نوبت هم به صورت چرخشی میده

هی به نوبت این ریسورس رو به بقیه بدیم پس اینجا باید یک جوری نوبت اعمال کنیم



Atomic Variables

- Typically, instructions such as compare-and-swap are used as building blocks for other synchronization tools.
- One tool is an atomic variable that provides atomic (uninterruptible) updates on basic data types such as integers and booleans.
- For example:
 - Let sequence be an atomic variable
 - Let increment() be operation on the atomic variable sequence
 - The Command:

```
increment(&sequence);
```

ensures **sequence** is incremented without interruption:



روش دیگه سخت افزاریه که وجود داره Atomic Variables است Atomic Variables در واقع امکان محدودتری برای ما است فقط مواقعی که ما جایی نیازمون با

increment کردن یک متغییر یا تغییر مقدار یک متغییر حل میشه می تونیم از Atomic Variables ستفاده بکنیم ینی همون متغییری که شیر است بین پروسس های مختلف رو اونو اتومیک تعریفش میکنیم و

توی دستور increment(&sequence) مطمئن میشیم که اگر جایی اون متغییر رو تغییر دادیم مثلاً توپی این دستور که روی متغییر sequence داره ایدیت صورت میگیره فقط همینی که داره اینو

تغییرش میده پنی اگر ترد دیگه ای هم همزمان می تونست این sequence رو تغییر بده چون این sequence یک متغییر اتومیک است اخرش منجر به این میشه که به ترتیب این ها این کار رو انجام بدن

اجرای این sequence به طور کامل بدون وقفه است و لود و استورش ممطمئنیم که کامل انجام میشه

پشت سر هم و مسئله ای پیش نمیاد

نکته: این Atomic Variables موقعی که می خوایم یک مقداری رو ایدیت بکنیم قابل استفاده

است و می تونیم مطمئن باشیم که ایدیت این ها همزمان انجام نمیشه

ولی ہمچنان یکسری مسائلی رو برای ما حل نمی کنه مثلاً توی اون مسئله باند بافر می خواستیم بافر محدود رو توی مسئله تولیدکننده و مصرف کننده حل بکنیم از یک کانتر استفاده میکر دیم اینجا می تونیم

الان کانتر رو اتومیک تعریف بکنیم پس مطمئن میشیم اون خط هایی که توش کانتر رو زیاد می کردیم یا کم می کردیم اتومیک اجرا میشن ولی باز مشکلی که پیش میاد این است اونجایی که داریم کانتر رو چک

میکنیم است پنی دوتا پروسس همزمان می تونن مقدار کانتر رو چک بکنن چون اپدیتش نمی کنن پس ممکنه دوتاشون همزمان وارد بخش بحرانی بشن و بازم مسئله رو نتونستیم اونجا حل بکنیم پس همچنان نیاز داریم بازم یکسری چیزهایی دیگه هم اضافه بکنیم به این روش ها که انواع مسئله های بخش بحرانی

رو بتونیم توی شرایط مختلف حل بکنیم



Atomic Variables

The increment() function can be implemented as follows:

```
void increment(atomic_int *v)
{
   int temp;
   do {
      temp = *v;
   }
   while (temp != (compare_and_swap(v,temp,temp+1));
}
```



مثال:

variables ها هم می تونن از طریق توابع compare_and_swap یا test and set پیاده بشن ینی ما وقتی که اعلام میکنیم که یک متغییر اتومیک است موقعی که میخوایم اپدیتش بکنیم باید

تابع increment رو با استفاده از compare_and_swap پیاده کرده ینی

از دستور compare_and_swap سخت آفزاری استفاده بکنیم بنی همچنان آون بیسیک ما همون

دستورها هستن حتی توی Atomic Variables هم بیسیک ما دستورهای سخت افزاری هستن که اینجا حتی اگر increment هم نبود هر مقدار جدیدی که میخواستیم بذاریم با استفاده از

اینجا کئی اگر micrement هم نبود هر مقدار جدیدی که میخوانسیم بداریم با استفاده از compare_and_swap

compare_and_swap هم مطمئن هستیم که همزمان کسی این متغییر v رو تغییر نمیده

Mutex Locks

- Previous solutions are complicated and generally inaccessible to application programmers
- OS designers build software tools to solve critical section problem
- Simplest is mutex lock
- Protect a critical section by first acquire() a lock then release() the lock
 - Boolean variable indicating if lock is available or not
- Calls to acquire() and release() must be atomic
 - Usually implemented via hardware atomic instructions such as compare-and-swap.

```
do {
    acquire lock
        critical section
    release lock
        remainder section
} while (true);
```

به دو روش خیلی معروفه که دولوپر ها در سطح یوزر هم می تونن از شون استفاده بکنن تا مسئله

خارج بشیم باید release بکنیم

بخش بحرانی کدشون رو حل بکنن روش اول یا Mutex خیلی شبیه همون lock که قبلا گفتیم می خوایم با صفر یا یک کردن بخش بحرانی رو مدیریت بکنیم و فقط یک نفر یکش بکنه

ولى اينجا دوتا تابع داريم: and release) و مطمئنیم که این دوتا اتومیک هستن

acquire(): اگر خواستیم که متغییر رو تغییر بدیم باید حتما lock اش رو در اختیار بگیریم که با

این تابع این کار رو می کنیم اگر پروسس دیگه ای این lock رو نگرفته بود می تونیم از acquire) رد بشیم ولی در غیر

اینصورت acquire) خودش بلاک میشه و اونقدر می مونه تا یه کسی که قبلا lock رو گرفته اونو release) اش بکنه و پروسس مدنظر بتونه از این قسمت رد بشه

همین دوتا تابع هم باید توسط compare_and_swap پیاده سازی بشن یا دستورهای سخت

افز ار ی توی این شکل: قبل از اینکه وارد بخش بحرانی بشیم باید lock رو acquire بکنیم و وقتی خواستیم

نکته: اگر دوتا ترد داشتیم که میخواستن یکیشون S1 رو تغییر بده و اون یکی هم S2 رو این دوتا می تونن این کارو بکنن چون روی یک متغییر نیست نکته ای که هست T1 باید acquire اش رو

روی S1 بذاره و T2 باید روی S2 بذاره

acquire() and release()

```
acquire() {
      while (!available) ; /* busy wait */
      available = false;
 release() {
      available = true;
   do {
  acquire lock
      critical section
   release lock
     remainder section
} while (true);
```

کار کلی که انجام میشه توی این دوتا تابع: acquire می خواد صبر بکنه روی یک مقدار متغییری که اون متغییر مثل lockمون می مونه و میگه اگر اون متغییر در دسترسه و کسی نگرفتش می تونی ازش رد بشی و اگر در دسترس نیست باید صبر بکنی و بعد خودت اونو فالسش بکنی همین کد رو می تونیم با compare-and-swap

و توی release هم صرفا مقدار متغییر رو برمی گردونه این دقیقا مثل اون خطی است که lock

که به compare-and-swap دادیم رو فالس می کردیم

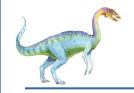












Semaphore

- Synchronization tool that provides more sophisticated ways (than Mutex locks) for processes to synchronize their activities.
- Semaphore S integer variable
- Can only be accessed via two indivisible (atomic) operations
 - wait() and signal()
 - Originally called P() and V()
- Definition of the wait() operation

```
wait(S) {

while (S <= 0)

; // busy wait

; // busy wait

s--;

cpu خرانی بشه هی باید این شرط حلقه S=> و چک بکنه و برای چک کردن این شرط سلط و پرای چک کردن این شرط این شرط این شرط و پرای چک کردن این شرط این شرط درج میشه
```

Definition of the signal() operation

```
signal(S) {
   S++;
}
```



روش دیگه ای که استفاده میشه استفاده از سمافور است سمافور: می تونه Mutex رو هم بپوشونه ینی سمافور امکانات Mutex رو هم داره ولی یکسری امکانات اضافی تری هم داره یک جاهایی است که از ریسورسمون بیشتر از یک المان داریم مثلا حافظه کامپیوتر ما اجازه نداریم یک خونه مشخص از این حافظه رو دسترسی همزمان به دوتا پروسس بدیم اما وقتی که p1 داره به یک قسمت حافظه دسترسی بیدا میکنه p2 می تونه به یک قسمت دیگه ای دسترسی داشته باشه و این کار هیچ مانعی نداره و ما به تعداد خونه های حافظه می تونه دستر سی های همز مان به این خونه های حافظه و جود داشته باشه چون این ریسورس حافظه ما مقدارش یک نیست مثلا برابر سایز این حافظه است پس اینجا یک ریسورسی داریم که صرفا اینطوری نیست که در یک لحظه فقط یک پروسس بتونه استفاده بکنه بیشتر از یک پروسس هم می تونه استفاده بکنه که به سایز این ریسورس برمیگرده که چه تعدادی می تونن از ش استفاده بکنن توی همچین حالتی می تونیم از سمافور ها استفاده بکنیم در واقع سمافور مقدار می تونه یک مقدار اینتجر باشه که می تونه بیشتر از یک باشه و ااگر مقدار سمافور یک بود پنی Mutex داریم پنی فقط یک پروسس می تونه در همون لحظه ازش استفاده بکنه ولی اگر دو بود ینی اجازه داریم دوتا پروسس همزمان ازش استفاده بكنن ولى پروسس سوم نميتونه ازش استفاده بكنه تا اينكه يكي از اين p2 or p1 اون ريسورس رو ازاد بكنن تا p3 بتونه از اون ريسورس استفاده بكنه اینجا هم دو تا تابع داریم: wait شبیه همون acquire است پنی صبر بکنه تا یکی از این پروسس ها از این ریسورس ازاد بشه و سیگنال شبیه release است پنی این p1 وقتی که می خواست این ریسورس رو پس بده به سیستم release ش کرد و وقتی که این p3 می خواست اون ریسورس رو بگیره wait گذاشت روش حالا اگر ازاد نبود باعث میشه که بلاک بشه روی اون خطو اگر ازاد بود می تونه بگیرتش و رد بشه بدنه کد داخل اسلاید است --> منطق کار شبیه کدی است که داخل اسلاید است ولی باز همین هم با استفاده از اون compare-and-swap پیاده سازی میکنیم توی wait همش باید چک بکنه که ببینه s کوچکتر و مساوی صفر هست یا نه اگر کوچکتر یا مساوی بود ینی هیچ ریسورسی از این نوع s نموندہ پس باید همین جا wait بکنه ینی پشت این while می مونه

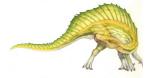
توی wait همش باید چک بکنه که ببینه s کوچکتر و مساوی صفر هست یا نه اگر کوچکتر یا مساوی بود ینی هیچ ریسورسی از این نوع s نمونده پس باید همین جا wait بکنه ینی پشت این while می مونه از اون طرف اگریک پروسسی قبلا این ریسورس رو گرفته بود ینی s رو گرفته بود و الان دیگه کاری باهاش نداره یک سیگنال فراخوانی می کنه و فراخوانی سیگنال باعث میشه که مقدار این سمافور یکی زیاد بشه و یکی که زیاد بشه سریعا توی wait مون s از صفر به یک تبدیل میشه و پروسسی که wait رو

فراخوانی کرده بود می تونه از اون خطرد بشه و مقدار ی رو کم بکنه



Semaphore (Cont.)

- Counting semaphore integer value can range over an unrestricted domain
- Binary semaphore integer value can range only between 0 and 1
 - Same as a mutex lock
- Can implement a counting semaphore S as a binary semaphore
- With semaphores we can solve various synchronization problems



به طور کلی این سمافور می تونه مقادیر مختلفی داشته اباشه توی حالتی که مقدارش بیشتر از یک

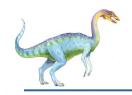
باشه بهش میگیم Counting semaphore و محدودیت نداریم که مقدار اولیه اش چند باشه ولی می تونیم اونو با یک ستش بکنیم و این باعث میشه که شبیه mutex عمل بکنه

توی مسائلی که می خوایم با سمافور حل بکنیم وقتی از سمافور داریم استفاده میکنیم حتما باید سمافور رو مقدار دهی اولیه بکنیم چون مهمه که مقدار اولیه اش چنده و وابسته به مقدار اولیه اش

است ولي mutex نه mutex هميشه مقدا اوليه اش از اده و صفره در واقع يا ميتونه صفر باشه يا

یک که مقدار اولیه اش باید از اد باشه که صفره ولی سمافور نه پنی کد نویس باید مشخص بکنه که

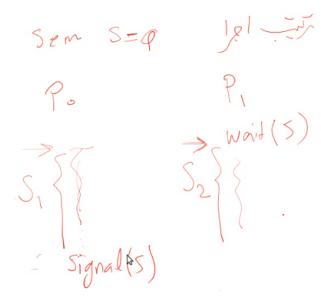
مقدار اولیه سمافور چنده و وابسته به شرایط و ریسورسی است که می خوایم استفاده بکنیم ---->>



Semaphore Usage Example

- Solution to the CS Problem
 - Create a semaphore "mutex" initialized to 1
 wait (mutex);
 CS
 signal (mutex);
- Consider P_1 and P_2 that with two statements S_1 and S_2 and the requirement that S_1 to happen before S_2
 - Create a semaphore "synch" initialized to 0

```
P1:
    S<sub>1</sub>;
    signal(synch);
P2:
    wait(synch);
    S<sub>2</sub>;
```





با استفاده از سمافور ما مي تونيم مسائل متفاوتي رو حل بكنيم از سمافور به جای mutex استفاده بکنیم: +

مثال: فرض کنید می خوایم این مسله رو حل بکنیم که به دوتا کد ترتیب اجرا بدیم ینی مطمئن باشیم که S1 پروسس p0 قبل از اجرای S2 اجرا میشه پنی اگر اسکجولینگ cpu هم به صورتی بود که

اول p1 اسكجول شد و رسيد به اين نقطه اول --> اگر S1 اجرا نشده بود S2 اجرا نشه يس اول باید یه جوری مطمئن بشیم S1 کامل اجرا بشه و بعد S2 اجرا بشه

اینجا بحث بخش بحرانی هم نیست بحث ترتیب اجرا است باید ترفند هایی به کار ببریم توی کدمون که اگر P1 اول اسکجول شد باعث موندن در ابتدا اون

بخش بشه تا P0 اسكجول بشه و S1 اجرا بكنه و بعد بياد سر S2

ر اه حل: با استفاده از سمافور اگر بخوایم اینو حل بکنیم باید یه جورایی از وارد شدن این P1 در اون بخش

جلوگیری بکنیم در صورتی که این Po هنوز وارد نشده باشه یک سمافوری تعریف کنیم اینجا به اسم S که مقدار اولیه اش رو صفر بدیم (مقدار سمافور رو

میتونیم هر مقدار غیر منفی بدیم) کاری که باید بکنیم اینه که باید قبل از اینکه P1 بتونه وارد اون قسمت بشه یک wait بذاره روی S

ولى براي P0 نه يني اون مي تونه بلافاصله اجرا بشه پس نياز نيست اونجا wait بذاريم ولي بايد وقتی که کارش تموم شد باید به P1 خبر بده پس انتهاش باید S رو سیگنال بکنه استفاده از این سمافور ها به این صورت خیلی دقت می خواد چون اگر درست استفاده نکنیم ممکنه که دچار بن بست بشیم

Example: Mistakes using semaphores

Let *S* and *Q* be two semaphores initialized to 1, What happens executing P0 and P1?

Deadlock – two or more processes are waiting indefinitely for an event that can be caused by only one of the waiting processes

مثال-

است:

یک نمونه دیگه از حالت هایی که ممکنه منجر به بن بست بشه با استفاده از سمافور ها این قطعه کد

بكنه كه P1 بتونه رد بشه ايا اين اتفاق مي تونه بيوفته اصلاً؟ خير چون خودش هم روى Q الان

منتظره --> پس هر دوتاشون اینجا بلاک میشن و باعث میشه هیچ وقت نتونن از اون قسمت خارج

اینجا دو تا سمافور تعریف شده که مقدار اولیه هر دو تا یک است ولی P0 اول روی S صبر کرده

در حالی که P1 اول روی Q صبر کرده که اینجا مشکلی نیست و هردوتا می تونن عبور بکنن ولی

بعدش P0 روی Q صبر کردہ و P1 روی S و اتفاقی که اینجا می افته این است که هر دو تاشون اپنجا می مونن و کی از اپنجا رد میشن در صورتی که برای پروسس مقابلی که wait کرده روی S

ینی P1 یکبار سیگنالش بکنه ینی پروسس P0 از wait(Q) رد باید بشه که بتونه S رو سگینال

بشن

Example: Bounded-Buffer Problem

- **n** buffers, each can hold one item
- Semaphore mutex initialized to the value 1
- Semaphore full initialized to the value 0
- Semaphore empty initialized to the value n

مثال:

نتونه بیشتر از n تا توی این بافر قرار بده و مصرف کننده هم اگر این بافر خالی بود چیزی نمیتونه

یک بافری داشتیم که اندازه اش n بود

یک سمافور full تعریف میکنیم که مقدار اولیه اش رو صفر می ذاریم

یک سمافور mutex تعریف میکنیم که مقدار اولیه اش یک است

سه تا سمافور تعریف میکنیم

یک سمافور empty تعریف میکنیم --> چندتا از خونه های بافر خالی است پس مقدار اولیه اش رو

ومسئله این است که تولیدکننده و مصرف کننده به طور صحیحی از این استفاده بکنند ینی تولیدکننده ازش برداره و باید منتظر بمونه تا داخلش پر بشه

ر اه حل:



Classical Problems of Synchronization

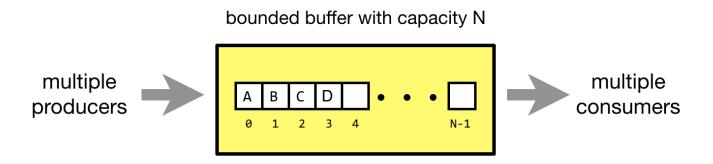
- Classical problems used to test newly-proposed synchronization schemes
 - Bounded-Buffer Problem
 - Readers and Writers Problem
 - Dining-Philosophers Problem





Bounded-Buffer Problem

- buffers, each can hold one item
- Semaphore mutex initialized to the value 1
- Semaphore full initialized to the value 0
- Semaphore empty initialized to the value n

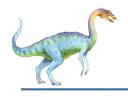




+ n بافر، هر کدام می توانند یک آیتم را در خود جای دهند + Semaphore mutex به مقدار 1 مقدار دهی اولیه شد

+ Semaphore full به مقدار دهی اولیه شد

+ سمافور خالی به مقدار ۱ مقدار دهی اولیه شده است

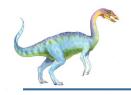


The structure of the producer process

```
while (true) {
    ...
    /* produce an item in next_produced */
    ...
    /* add next produced to the buffer */
    ...
```

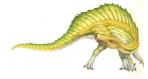
}

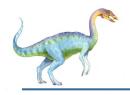




The structure of the producer process

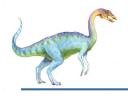
```
while (true) {
     /* produce an item in next produced */
   wait(empty);
   wait(mutex);
     /* add next produced to the buffer */
   signal(mutex);
   signal(full);
```





The structure of the consumer process

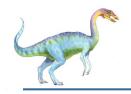
```
while (true) {
   /* remove an item from buffer to next consumed */
     /* consume the item in next consumed */
```



The structure of the consumer process

```
while (true) {
   wait(full);
   wait(mutex);
   /* remove an item from buffer to next consumed */
   signal(mutex);
   signal(empty);
     /* consume the item in next consumed */
```





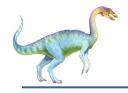
Semaphore Implementation

- Must guarantee that no two processes can execute the wait() and signal() on the same semaphore at the same time
- Thus, the implementation becomes the critical section problem where the wait and signal code are placed in the critical section
- Could now have busy waiting in critical section implementation
 - But implementation code is short
 - Little busy waiting if critical section rarely occupied
- Note that applications may spend lots of time in critical sections and therefore this is not a good solution



-

busy waiting ینی جایی که ما cpu رو مشغول یک کار بیهوده ای کردیم ینی یک پروسسه ای که صرفا داره wait می کنه یه جایی و با wait کردنش داره cpu خرج میکنه



Semaphore Implementation with no Busy waiting

- With each semaphore there is an associated waiting queue
- Each entry in a waiting queue has two data items:
 - Value (of type integer)
 - Pointer to next record in the list.
- Two operations:
 - block place the process invoking the operation on the appropriate waiting queue
 - wakeup remove one of processes in the waiting queue and place it in the ready queue



توی بحث پروسس ها و مدیریت و زمان بندیشون یک صف داشتیم برای پروسسس ها و وقتی یک

انتظارها و دیگه ready نبود و اسکجولر هم از صف ready ها یک پروسسی رو انتخاب میکرد و بهش cpu می داد از این نکته می خوایم استفاده بکنیم برای پیاده سازی سمافور به صورتی که busy waiting رخ نده

پروسس می رفت توی حالت 0/ا یا می خواست منتظر یک وقفه ای باشه می رفت توی صف

اینجا برای هر سمافوری یک صفی تعریف میکنیم صفحه بعدی...

صفحه بعدی... اگر این سمافور هیچ ریسورسیش از اد نبود و یک پروسس در خواست ریسوس داشت باید اول بلاکش

اگر این سمافور هیچ ریسورسیش از اد نبود و یک پروسس درخواست ریسوس داشت باید اول بلاکش بکنیم و بلاک کردن یک پروسس به این معناست که دیگه بهش cpu داده نمیشه و اسکجولر دیگه

بعدیم و بعدت حردن یک پروسش به این معداست که دیکه بهش cpu داده نمیسه و استجوار دیکه هیچ وقت انتخابش نمیکنه

وخودمون هم برای اینکه بخوایم از بلاک درش بیاریم می گذاریم توی اون صفی که توی سمافورمون داریم ینی struct process *list و در مقابل بلاک یک تابع wakeup داریم که این wakeup باعث مبشه که اون بر و سس دوباره جز readv ها حساب بشه و cpu بهش تعلق بگیره

wakeup باعث میشه که اون پروسس دوباره جز ready ها حساب بشه و cpu بهش تعلق بگیره پس وقتی که یک پروسسی به یک نقطه ای رسید و یک ریسورسی می خواست که ازاد نبود اینجا

آینو وارد یک صفی می کنیم که همون صف سمافور است و آز طرفی هم اینجا براش بلاک رو فراخوانی میکنیم و دیگه هیچ وقت cpu اینو انتخابش نمیکنه مگر اینکه یک جا دیگه این wakeup

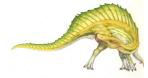
قراحواتی میکنیم و دیکه هیچ وقت cpu اینو انتخابش نمیکنه مکر اینکه یک بی دیکه این wakeup بشه



Implementation with no Busy waiting (Cont.)

Waiting queue

```
typedef struct {
  int value;
  struct process *list;
} semaphore;
```



یک استراکچری اینجا تعریف میکنیم برای خود سمافور که این یک مقداری داره که همون مقدار



Implementation with no Busy waiting (Cont.)

```
wait(semaphore *S) {
   S->value--;
   if (S->value < 0) {
      add this process to S->list;
      block();
signal(semaphore *S)
S->value++;
   if (S->value <= 0) {
      remove a process P from S->list;
      wakeup(P);
```

Operating System Concepts - 10th Edition

6 24

Silberschatz, Galvin and Gagne ©2018

کد wait و سیگنال رو چجوری با حرفایی که قبلا زدیم الان بنویسیم؟ wait رو وقتی که می خوایم بنویسیم بخاطر اینکه اونایی که ریسورس براشون از اد نیست رو باز می خوایم ببریمشون توی اون صفه یه جا باید یک روش تشخیصی هم داشته باشیم که کیا توی صف

هستن پس value سمافور رو به هر حال همیشه کم میکنیم

سیگنال در مقابل داره خط اول مقدار value یکی زیاد میکنه و بعد از اینکه یکی زیاد کرد چک میکنه اگر این value<=0 است پس حتما قبلا یک پروسسی بوده که مقدار این S رو منفی کرده

بوده و باعث شده بود که بره توی لیست انتظارها پس باید الان اون پروسس رو از توی لیست در ش

بیاریم و wakeupاش بکنیم درمقابل اون طرف توی wait اگر ببینه مقدار value<0 شد ینی قبل از اینکه این پروسس فعلی

بیاد و مقدار S رو کم بکنه صفر شده بوده و ریسورسی ما نداشتیم پس ما اینجا اول باید اونو اضافه بكنيم به ليست waiting اون سمافورمون و بعد بلاكش

توی این مثال دیگه ما Busy waiting نداریم